



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 男男大学

参赛队号 4321

队员姓名	1. 队员 A
	2. 队员 B
	3. 队员 C

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

数学建模

关键词： 模板 $\text{\LaTeX}$ 数学建模

目录

1	问题重述	3
2	模型假设	4
3	定义与符号说明	4
4	问题一	5
4.1	问题分析	5
4.2	模型建立	6
4.2.1	列表型质量信号标量化	6
4.2.2	方向统一与缺失处理	6
4.2.3	受限 CRITIC 权重	7
4.2.4	Huber 鲁棒综合质量分	7
4.2.5	冲突定义、置信度与成因贡献	7
4.2.6	领域聚合与扩展集检验	8
4.2.7	ILR 坐标	8
4.2.8	二次多输出岭回归	8
4.2.9	验证指标与跨规模迁移	9
4.2.10	领域边际效应与组合效应	9
4.2.11	质量与配比的部分识别	9
4.3	建模结果	10
4.3.1	领域质量评分	10
4.3.2	A1 与扩展集的一致性	11
4.3.3	冲突结构与消解结果	11
4.3.4	配比模型验证	12
4.3.5	领域主效应	13
4.3.6	领域组合效应	14
4.3.7	质量映射覆盖与不可辨识性	15
4.3.8	外推稳定性	16
4.3.9	小结	16
5	问题二	17
5.1	问题分析	17
5.2	模型建立	17
5.3	建模结果	17

6 问题三	17
6.1 问题分析	17
6.2 模型建立	17
6.3 建模结果	17
7 问题四	17
7.1 问题分析	17
7.2 模型建立	17
7.3 建模结果	17
8 模型评价	17
参考文献	17
附录 A MATLAB 源程序	18
A.1 第 1 问程序	18
附录 B Python 源程序	19
B.1 第 2 问程序	19

1 问题重述

问题一：

附件 A 给出两类数据。

第一类为 A1–A3 的质量信号数据，每条文本包含 22 个质量指标，其中既有教育价值、流畅度、可读性等正向指标，也有广告概率、重复比例等负向指标，还有文本长度、数字比例等不宜简单假定单调优劣的指标。题目要求使用 A1 抽样集以及 A2、A3 扩展集的全部记录，建立样本级和领域级质量评分 Q ，并检验扩展集与抽样集是否具有一致结论。当不同指标对同一文本给出显著不一致的判断时，还需定义冲突、分析来源并提出消解方法。

第二类为 A4–A15 的 RegMix 配方实验数据。每个配方由 17 个 The Pile 子领域的份额构成，份额非负且和为 1；对应结果为 13 个验证领域的交叉熵 Loss。需要利用 A4/A5 建模，在 A6–A11 的 1M、60M、1B 检验集上验证，并利用 A12–A15 讨论 10B 和 70B 外推结论的稳健性。由于质量信号领域和配方领域并不完全一致，若将 Q 引入配比模型，必须说明映射、可辨识性和不确定性。

2 模型假设

- H1.** 附件中标记为真实的数据能够代表对应数据源；半合成、子集和外推数据按其标记使用，不与真实实验混同。
- H2.** 二分类列表的末位为正类 logits，ModernBERT 六维输出的类别顺序与质量等级一致；若原始模型标签顺序相反，应在代码配置中同步调整。
- H3.** A1 可作为 22 个质量指标归一化和权重估计的参考样本，A2/A3 只用于扩展验证和相应领域最终评分。
- H4.** 配比表中的舍入误差可通过闭合操作修正；加入小伪计数后，零份额的对数比可以稳定计算。
- H5.** 二次响应面只解释观测配方邻域内的关联效应，有限差分不被解释为全局因果效应。
- H6.** 不同参数规模改变绝对 Loss 基准，但配方优劣排序可能迁移，因此跨规模以秩相关为主要评价标准。

3 定义与符号说明

表 3.1 主要符号

符号	含义
i, j, d, k, r, s	文本、质量指标、质量领域、配方领域、Loss 验证域、模型规模的下标
x_{ij}	列表压缩后的原始质量指标
S_{ij}	方向统一后的质量得分，取值在 $[0, 1]$
w_j	第 j 个质量指标的受限 CRITIC 权重
Q_i, Q_d	文本级综合质量与领域级质量
D_i, R_i	文本的加权分歧度与 90%–10% 稳健极差
$Conf_i$	文本质量评分置信度
$\mathbf{p}_i$	17 维领域配比，满足非负且和为 1
$\mathbf{z}_i$	配比的 16 维 ILR 坐标
$L_{ir}, \hat{L}_{ir}$	观测和预测的第 r 个验证域 Loss
ME_k, INT_{jk}	领域边际效应和两领域二阶组合效应

4 问题一

4.1 问题分析

质量信号的主要困难不是简单加权，而是输出结构和语义不同。二分类模型输出 logits，有序分类器输出 6 维 logits，Qurater 给出多个并列侧面，而 RedPajama 统计量为连续标量。若直接对列表取均值，会混淆概率、等级和不同侧面的含义。其次，“词数越多越好”或“数字比例越低越好”并不适用于所有领域，必须将这类指标视为目标型而非强行设定单调方向。最后，扩展集中 arxiv 和 github 的记录数远大于其他领域，若直接用全体数据估计权重，会让领域规模影响指标权重。因此本文只用覆盖 7 个领域的 A1 估计归一化参数和权重，再把同一变换应用到 A2/A3。

质量指标的分歧可能来自真实的多面性，也可能来自分类器误差、文本格式或极端长度。仅用最大值减最小值会被单项异常放大，仅用方差又可能把多个指标的系统性对立平均掉。本文联合使用加权分歧度和 90%–10% 稳健极差，并以 A1 分歧度的高分位数确定阈值。综合评分采用 Huber 估计，使冲突记录中的离群指标自动降权，而不是删除整条文本。

17 个领域份额属于成分数据。直接在原始占比上做普通最小二乘会受到定和约束、完全共线性和伪相关的影响 [1]。同时，13 个验证域的 Loss 相关但不完全相同，需要多输出建模。RegMix 的训练表只有 512 个配方，若使用高复杂度黑箱模型，不利于效应解释且容易过拟合。本文采用 ILR 坐标上的二次岭回归：ILR 解除单纯形约束，二次项表达组合关系，岭惩罚控制参数方差。

问题一建模流程




图 4.1 问题一建模流程 (待更新)

4.2 模型建立

4.2.1 列表型质量信号标量化

设文本 i 的指标 j 原始输出为 x_{ij} 。标量字段直接保留；8 个列表型字段按输出含义处理。

对 ‘fluency_en’ 和 ‘ad_en’ 的二分类 logits (a_0, a_1)，取正类概率：

$$x_{ij} = \frac{\exp(a_1)}{\exp(a_0) + \exp(a_1)}. \quad (4.1)$$

对四个 ‘modernbert_’ 的 6 级有序 logits，取归一化期望等级：

$$x_{ij} = \sum_{c=0}^5 \frac{c}{5} \frac{\exp(a_c)}{\sum_{h=0}^5 \exp(a_h)}. \quad (4.2)$$

‘qurater’ 的四个分量表示并列质量侧面，分别经逻辑函数后求平均：

$$x_{ij} = \frac{1}{4} \sum_{c=1}^4 \frac{1}{1 + \exp(-a_c)}. \quad (4.3)$$

‘fineweb_edu’ 的列表仅含一个元素，直接取其值。这样避免了对 logits 直接平均造成的量纲错误。

4.2.2 方向统一与缺失处理

以 A1 为参考样本，计算指标 j 的 1%、50%、99% 分位数 $q_{.01,j}, q_{.50,j}, q_{.99,j}$ ，并将极端值缩尾到该区间。效益型指标转换为

$$S_{ij} = \frac{(x_{ij}) - q_{.01,j}}{q_{.99,j} - q_{.01,j}}, \quad (4.4)$$

成本型指标转换为

$$S_{ij} = 1 - \frac{(x_{ij}) - q_{.01,j}}{q_{.99,j} - q_{.01,j}}. \quad (4.5)$$

词数、句数、数字比例和平均词长设为目标型指标：

$$S_{ij} = \begin{cases} 1 - \frac{q_{.50,j} - x_{ij}}{q_{.50,j} - q_{.01,j}}, & x_{ij} \leq q_{.50,j}, \\ 1 - \frac{x_{ij} - q_{.50,j}}{q_{.99,j} - q_{.50,j}}, & x_{ij} > q_{.50,j}. \end{cases} \quad (4.6)$$

所有结果截断到 $[0, 1]$ ，从而统一为越高越好。缺失值先用同领域中位数填补，再用 A1 全局中位数兜底；另保留原始覆盖率，防止填补后的记录被误认为信息完整。

4.2.3 受限 CRITIC 权重

在方向统一后的 A1 得分上计算标准差 σ_j 和相关系数 ρ_{jh} 。CRITIC 方法 [2] 把变异性和非冗余性结合为

$$C_j = \sigma_j \sum_{h=1}^{22} (1 - |\rho_{jh}|), \quad w_j^{(c)} = \frac{C_j}{\sum_h C_h}. \quad (4.7)$$

为避免噪声造成权重过度集中，将 CRITIC 权重与等权重各占一半，并限制单项范围：

$$\tilde{w}_j = \frac{1}{2} \frac{1}{22} + \frac{1}{2} w_j^{(c)}, \quad w_j = \frac{(\tilde{w}_j, 0.5/22, 2/22)}{\sum_h (\tilde{w}_h, 0.5/22, 2/22)}. \quad (4.8)$$

全量运行中，数字字符比例、专业性、句数、词数和流畅度权重较高，分别为 0.0609、0.0548、0.0538、0.0527 和 0.0526；全部指标仍保留正权重。

4.2.4 Huber 鲁棒综合质量分

若直接取加权均值，单个严重偏离的指标仍可能拉动结果。本文采用加权 Huber 位置估计 [3]：

$$Q_i = \arg \min_{q \in [0,1]} \sum_{j=1}^{22} w_j \rho_{1.345} \left(\frac{S_{ij} - q}{\hat{\sigma}_i} \right), \quad (4.9)$$

其中

$$\hat{\sigma}_i = 1.4826 \operatorname{median}_j |S_{ij} - q|, \quad \rho_c(u) = \begin{cases} \frac{1}{2} u^2, & |u| \leq c, \\ c|u| - \frac{1}{2} c^2, & |u| > c. \end{cases} \quad (4.10)$$

通过迭代重加权求解式 (4.9)。在指标一致时，该估计接近加权均值；出现少数异常指标时，其边际权重随残差增大而下降。

4.2.5 冲突定义、置信度与成因贡献

定义加权分歧度和稳健极差为

$$D_i = \sqrt{\sum_j w_j (S_{ij} - Q_i)^2}, \quad R_i = P_{90}(S_{i\cdot}) - P_{10}(S_{i\cdot}). \quad (4.11)$$

以 A1 的 D_i 的 95% 分位数为 τ_D ，显著冲突定义为

$$I_i = (D_i > \tau_D \wedge R_i > 0.60). \quad (4.12)$$

全量计算得到 $\tau_D = 0.38725$ 。联合条件既要求总体分歧较大，也要求指标两端存在实质距离。

评分置信度定义为

$$\operatorname{Conf}_i = \operatorname{Coverage}_i \left(1 - \min \left\{ \frac{D_i}{0.50}, 1 \right\} \right). \quad (4.13)$$

指标 j 对全部冲突的归一化贡献为

$$A_j = \frac{\sum_{i:I_i=1} [w_j | S_{ij} - Q_i|]}{\sum_h \sum_{i:I_i=1} [w_h | S_{ih} - Q_i|]}. \quad (4.14)$$

该贡献只用于定位分歧来源，不把某一指标直接判定为错误。

4.2.6 领域聚合与扩展集检验

领域质量取领域内文本质量均值：

$$Q_d = \frac{1}{n_d} \sum_{i:g(i)=d} Q_i. \quad (4.15)$$

同时报告均值标准误区间、冲突率和平均置信度。arxiv、github 分别比较 A1 与扩展集的均值差、Cohen's d 和两样本 KS 统计量。最终领域评分中，这两个领域使用扩展集估计；其余领域使用 A1，避免 A1 与扩展集可能重合的记录被重复计数。

4.2.7 ILR 坐标

配比向量属于 16 维单纯形：

$$\mathbf{p}_i \in \mathcal{S}^{16} = \left\{ \mathbf{p} : p_k \geq 0, \sum_{k=1}^{17} p_k = 1 \right\}. \quad (4.16)$$

对零分量加入 $\epsilon = 10^{-4}$ 后重新闭合：

$$\tilde{p}_{ik} = \frac{p_{ik} + \epsilon}{\sum_h (p_{ih} + \epsilon)}. \quad (4.17)$$

令 $H \in \mathbb{R}^{16 \times 17}$ 为 Helmert 正交对比矩阵，则 ILR 坐标为

$$\mathbf{z}_i = H \left(\log \tilde{\mathbf{p}}_i - \frac{1}{17} \mathbf{1} \mathbf{1}^\top \log \tilde{\mathbf{p}}_i \right). \quad (4.18)$$

该变换保留 Aitchison 几何距离，并消除任意删去一个配比分量带来的解释依赖。

4.2.8 二次多输出岭回归

对 13 个验证域分别建立共享正则强度的二次响应面：

$$L_{ir} = \beta_{0r} + \boldsymbol{\beta}_r^\top \mathbf{z}_i + \mathbf{z}_i^\top \Gamma_r \mathbf{z}_i + \varepsilon_{ir}. \quad (4.19)$$

参数通过

$$\min_{\boldsymbol{\beta}, \Gamma} \sum_{i,r} (L_{ir} - \hat{L}_{ir})^2 + \lambda (\|\boldsymbol{\beta}\|_2^2 + \|\Gamma\|_F^2) \quad (4.20)$$

估计。五折交叉验证在 10^{-4} 至 10^4 的对数网格上选择 λ ，最终得到 $\lambda = 10$ 。二次项表达领域对之间的非可加关系，岭惩罚用于控制 512 个样本下的估计方差。

4.2.9 验证指标与跨规模迁移

同规模检验报告 RMSE、MAE、方差加权 R^2 和 13 个目标 Spearman 相关的均值。对 60M、1B，主指标为

$$\bar{\rho}_s = \frac{1}{13} \sum_{r=1}^{13} \text{Spearman}(L_{sr}, \hat{L}_{1M,r}). \quad (4.21)$$

为区分“排序可迁移”和“绝对标尺已改变”，另拟合 $L_{sr} = a_{sr} + b_{sr} \hat{L}_{1M,r} + e$ 给出描述性校准误差。该校准使用检验标签，只用于判断单调关系，不作为独立预测成绩。

4.2.10 领域边际效应与组合效应

将领域 k 的份额增加 $\delta = 0.01$ ，其余领域按比例缩减，记为 $T_k(\mathbf{p}, \delta)$ 。平均边际效应为

$$ME_k = \mathbf{p} \left[\frac{\bar{L}(T_k(\mathbf{p}, \delta)) - \bar{L}(\mathbf{p})}{\delta} \right], \quad \bar{L} = \frac{1}{13} \sum_r L_r. \quad (4.22)$$

两领域组合的二阶差分为

$$INT_{jk} = \frac{\bar{L}(T_{jk}) - \bar{L}(T_j) - \bar{L}(T_k) + \bar{L}(\mathbf{p})}{\delta^2}. \quad (4.23)$$

$ME_k < 0$ 表示在观测配方邻域内增加该域通常降低平均 Loss； $INT_{jk} < 0$ 表示组合降低 Loss 超过可加预期。

4.2.11 质量与配比的部分识别

A16 只为 arxiv、github、stackexchange、wikipedia_en、gutenberg_pg_19、pile_cc 提供直接或近直接质量映射。记已映射集合为 M ：

$$K(\mathbf{p}) = \sum_{k \in M} p_k Q_{m(k)}, \quad c(\mathbf{p}) = \sum_{k \in M} p_k. \quad (4.24)$$

对未映射质量不作主观点估计，而以观测领域质量范围给出

$$Q_{mix} \in [K + (1 - c)Q_{min}, K + (1 - c)Q_{max}]. \quad (4.25)$$

中点敏感性值为

$$Q_{mix}^{mid} = K + (1 - c)\bar{Q}. \quad (4.26)$$

由于式 (4.26) 本身是配比的线性组合，将其与 17 个配比变量同时进入回归无法识别独立质量效应。因此本文将它用于解释覆盖度和不确定区间，不重复估计所谓“质量系数”。

4.3 建模结果

4.3.1 领域质量评分

表 4.1 给出最终选择的数据源和领域质量。arxiv 与 commoncrawl 的平均质量最高, 均约为 0.717; github 为 0.545。book 只有 171 条记录, 95% 区间更宽且冲突率达到 56.73%, 因此其排名不宜过度解释。

表 4.2 领域质量评分与冲突率

领域	最终数据源	样本量	Q	冲突率/%
arxiv	A2 扩展集	17,523	0.71684	21.59
book	A1 抽样集	171	0.49113	56.73
c4	A1 抽样集	10,000	0.67606	10.67
commoncrawl	A1 抽样集	9,640	0.71664	0.33
github	A3 扩展集	203,752	0.54470	7.15
stackexchange	A1 抽样集	10,000	0.66447	0.14
wikipedia	A1 抽样集	10,000	0.59758	3.55




图 4.2 最终领域质量评分

4.3.2 A1 与扩展集的一致性

表 4.3 显示，arxiv 扩展集的平均质量比 A1 抽样低 0.00604，Cohen's $d = -0.0700$ ；github 的均值差仅 -0.00126 ，Cohen's $d = -0.0144$ 。arxiv 的 KS 检验因样本量大而达到统计显著，但效应量很小，不能据此声称抽样集与扩展集存在实质性质量差异。github 的分布差异也很小。扩展结果支持 A1 对这两个领域的均值代表性。

表 4.3 A1 抽样与扩展集质量对照

领域	n_{A1}	n_{ext}	Q_{A1}	Q_{ext}	均值差	Cohen's d
arxiv	1,419	17,523	0.72287	0.71684	-0.00604	-0.0700
github	10,000	203,752	0.54596	0.54470	-0.00126	-0.0144




图 4.3 A1 抽样与 A2/A3 扩展集平均质量比较

4.3.3 冲突结构与消解结果

全体 272,505 条记录的冲突率为 7.675%。冲突贡献最高的指标为数字字符比例、词数、最高频三元字符比例、句数、最高频二元字符比例和广告信号，归一化贡献分别为 0.0617、0.0607、0.0569、0.0542、0.0538 和 0.0523。该结果说明冲突主要来自文本结构、长度和重复特征与模型型质量分之间的分歧，而非某个单一指标完全失效。




图 4.4 冲突记录中的主要指标贡献

Huber 聚合在冲突样本中降低大残差指标的有效权重，同时保留文本记录和其余指标。相比“检测冲突后删除样本”，该处理不会系统性排除包含公式、代码或特殊格式的高价值文本。置信度 $Conf_i$ 则将分歧程度和原始覆盖率显式保留下来，便于后续模型使用质量分时进行筛选或加权。

4.3.4 配比模型验证

表 8.5 给出三组真实检验结果。1M 同规模检验取得 RMSE 0.28465、MAE 0.20269、 $R^2 = 0.86473$ ，平均 Spearman 为 0.93396，说明二次 ILR 岭回归能够同时解释多数验证域的配比差异。

60M 和 1B 的未校准 R^2 为负，原因是模型规模改变了绝对 Loss 基准，而非配方排序失效。二者的平均 Spearman 仍为 0.92950 和 0.84253。使用检验标签做每个目标的一维仿射校准后， R^2 分别达到 0.85178 和 0.81292；该结果只说明单调结构可通过尺度和平移校准，不视为独立预测性能。

表 4.4 A6–A11 配比模型验证结果

检验集	RMSE	MAE	R^2	平均 Spearman	校准 RMSE	校准 R^2
1M	0.28465	0.20269	0.86473	0.93396	0.27409	0.87458
60M	1.59999	1.50659	-7.30804	0.92950	0.21371	0.85178
1B	2.70008	2.62433	-189.99642	0.84253	0.08450	0.81292

注：60M、1B 的仿射校准使用相应检验标签，只用于描述跨规模单调迁移，不是独立预测。




图 4.5 不同参数规模下的配方排序迁移

4.3.5 领域主效应

图 4.5 展示在 200 个训练配方附近计算的平均局部导数。`dm_mathematics`、`ubuntu_irc`、`stackexchange` 的平均导数分别为 -7.216 、 -6.711 、 -6.515 ，即增加 1 个百分点份额时，平均 Loss 的预测变化约为 -0.0722 、 -0.0671 、 -0.0651 。`enron_emails`、`europarl` 和 `gutenberg_pg_19` 的导数为正。由于不同参考配方下的导数标准差较大，这些数值应理解为样本分布上的平均局部关联。

表 4.5 绝对值较大的领域局部边际效应

领域	ME_k	标准差	局部解释
dm_mathematics	-7.216	7.897	增加份额通常降低 Loss
ubuntu_irc	-6.711	7.256	增加份额通常降低 Loss
stackexchange	-6.515	9.119	增加份额通常降低 Loss
enron_emails	5.354	14.464	增加份额通常提高 Loss
freelaw	-3.545	8.092	增加份额通常降低 Loss
arxiv	-3.160	6.573	增加份额通常降低 Loss
github	-3.139	7.928	增加份额通常降低 Loss
europarl	2.252	8.100	增加份额通常提高 Loss




图 4.6 17 个训练领域对平均 Loss 的局部边际效应

4.3.6 领域组合效应

二阶差分绝对值最大的组合多涉及样本中较稀疏的 philpapers、nih_exporter 和 enron_emails。例如 philpapers-enron_emails 的 $INT = 87.85$ ，表示组合效果弱于主效应可

加预期；enron_emails–europarl 的 $INT = -18.33$ ，表现为局部协同。由于二阶效应对配方位置和伪计数更敏感，本文只把其作为筛选需要进一步实验的领域组合，不把数值直接解释为稳定因果效应。

表 4.6 绝对值最大的领域组合效应

领域 1	领域 2	INT_{jk}	类型
philpapers	enron_emails	87.85	拮抗
nih_exporter	philpapers	59.38	拮抗
nih_exporter	enron_emails	51.52	拮抗
enron_emails	hackernews	44.71	拮抗
philpapers	europarl	27.07	拮抗
enron_emails	europarl	-18.33	协同
enron_emails	gutenberg_pg_19	17.38	拮抗
nih_exporter	europarl	13.44	拮抗

4.3.7 质量映射覆盖与不可辨识性

A16 的直接或近直接映射只覆盖 6 个配方域。训练配方的平均已映射质量为 0.5646，1M/60M 检验为 0.5690，1B 为 0.6224；不同配方的覆盖质量从接近 0 到 1 不等。训练集的 Q_{mix} 部分识别区间平均宽度为 0.0983，1M/60M 为 0.0973，1B 为 0.0852。该宽度表明，对未映射 11 域强行填入单一质量分会制造不可忽略的模型确定性。本文因此保留上下界，并将 Q_{mix}^{mid} 只作为敏感性描述量。

表 4.7 配方质量映射覆盖情况

数据集	样本量	平均映射质量	最小-最大映射质量	平均区间宽度
训练 1M	512	0.5646	0.000–1.000	0.0983
检验 1M	256	0.5690	0.001–1.000	0.0973
检验 60M	256	0.5690	0.001–1.000	0.0973
检验 1B	64	0.6224	0.138–0.888	0.0852
外推 10B/70B	各 63	0.5435	0.003–1.000	0.1030

4.3.8 外推稳定性

A12–A15 上的未校准绝对误差很大，符合模型规模改变 Loss 基准的预期。10B 和 70B 的配方排序平均 Spearman 分别为 0.60949 和 0.52874；使用外推标签做仿射校准后 R^2 分别为 0.57882 和 0.45793。该结果说明效应排序具有中等稳定性，但明显弱于真实 60M/1B 检验。由于外推配比为训练子集、Loss 也来自外推，本文不把它作为真实大模型实验验证。

表 4.8 A12–A15 外推稳定性结果

数据集	未校准 RMSE	平均 Spearman	校准 RMSE	校准 R^2
10B 外推	3.62349	0.60949	0.17124	0.57882
70B 外推	4.01115	0.52874	0.16192	0.45793

4.3.9 小结

本节完成了问题一的质量评价、冲突消解和领域配比建模。基于 272,505 条记录构建的 Huber 综合质量分能够统一 22 个异质指标。arxiv 与 commoncrawl 的领域质量最高，github 与 book 较低；book 的样本量和冲突结构使其不确定性更大。总体冲突率为 7.675%。冲突主要与数字比例、文本长度和重复统计有关。Huber 估计能够在不删除文本的情况下抑制离群指标。arxiv、github 的扩展集与 A1 抽样集平均质量差异很小，Cohen’s d 的绝对值均小于 0.08，支持 A1 的均值代表性 ILR 二次岭回归在 1M 检验集上达到 $R^2 = 0.86473$ ，跨到 60M 和 1B 后配方排序相关仍为 0.92950 和 0.84253。配比规律主要以相对排序形式迁移，绝对 Loss 需要规模校准在观测配方邻域内，dm_mathematics、

ubuntu_irc、stackexchange 的平均边际效应最有利；enron_emails 的平均效应不利。该结论仅适用于局部调整。A16 的映射覆盖不足以识别独立质量系数。部分识别区间比主观补值更诚实，也为问题二引入质量因素提供了不确定性边界。

5 问题二

5.1 问题分析

5.2 模型建立

5.3 建模结果

6 问题三

6.1 问题分析

6.2 模型建立

6.3 建模结果

7 问题四

7.1 问题分析

7.2 模型建立

7.3 建模结果

8 模型评价

模型评价

参考文献

[1] ... 参考一

[2] ... 参考二

附录 A MATLAB 源程序

A.1 第 1 问程序

code.m

```
clear all
kk=2;
[mdd, ndd]=size(dd);
while ~isempty(V)
    [tmpd, j]=min(W(i, V));
    tmpj=V(j);
    for k=2:ndd
        [tmp1, jj]=min(dd(1, k)+W(dd(2, k), V));
        tmp2=V(jj);
        tt(k-1, :)= [tmp1, tmp2, jj];
    end
    tmp=[tmpd, tmpj, j; tt];
    [tmp3, tmp4]=min(tmp(:, 1));
    if tmp3==tmpd,
        ss(1:2, kk)= [i; tmp(tmp4, 2)];
    else
        tmp5=find(ss(:, tmp4)~=0);
        tmp6=length(tmp5);
        if dd(2, tmp4)==ss(tmp6, tmp4)
            ss(1:tmp6+1, kk)= [ss(tmp5, tmp4); tmp(tmp4, 2)];
        else, ss(1:3, kk)= [i; dd(2, tmp4); tmp(tmp4, 2)];
        end
    end
    end
    dd=[dd, [tmp3; tmp(tmp4, 2)]];
    V(tmp(tmp4, 3))=[];
    [mdd, ndd]=size(dd); kk=kk+1;
end;
S=ss; D=dd(1, :);
```

附录 B Python 源程序

B.1 第 2 问程序

mip1.py

```
# This example formulates and solves the following
MIP model:
# maximize
#      x + y + 2 z
# subject to
#      x + 2 y + 3 z <= 4
#      x + y      >= 1
#      x, y, z binary

# import gurobipy as gp
from gurobipy import * #GRB
try:
    # Create a new model
    m = Model("mip1")
    # Create variables
    x = m.addVar(vtype=GRB.BINARY, name="x")
    y = m.addVar(vtype=GRB.BINARY, name="y")
    z = m.addVar(vtype=GRB.BINARY, name="z")
    # Set objective
    m.setObjective(x + y + 2 * z, GRB.MAXIMIZE)
    # Add constraint: x + 2 y + 3 z <= 4
    m.addConstr(x + 2 * y + 3 * z <= 4, "c0")
    # Add constraint: x + y >= 1
    m.addConstr(x + y >= 1, "c1")
    # Optimize model
    m.optimize()
    for v in m.getVars():
        print('%s %g' % (v.varName, v.x))
    print('Obj: %g' % m.objVal)

except GurobiError as e:
    print('Error code ' + str(e.errno) + ': ' + str(e))

except AttributeError:
    print('Encountered an attribute error')
```