

# 数据说明

对应赛题《算力约束下提升大语言模型能力的资源配置建模》。本说明给出各数据文件的结构、字段与跨附件兼容性；各文件均使用英文文件名，赛题正文中以编号 A1–A18、B1–B12、C1–C10 指代，编号与英文文件名的对照见《编号与读取速查》。

本赛题以真实公开数据为主，并包含经真实数据校准、已明确标注的半合成补充数据。全部附件位于 `real_attachments/` 目录下，本文所有路径均相对于该目录。按实际文件占用的存储空间（即磁盘上的字节数）统计，总体积约 0.55 GB（压缩后，原始约 1.66 GB），其中绝大部分为必用数据（见《强制使用清单》）。参赛队伍可在个人电脑上使用 Python、Matlab 或 R 完成全部处理，无须 GPU。

如本文档、`source_manifest.json`、`attachment_size_summary.csv` 与实际文件出现差异，以实际附件为准。

## 编号与读取速查

本节集中给出编号索引、各文件绑定问题与读取要求，便于与赛题正文分开查阅。各文件的完整字段与规模见后文《附件 A/B/C》各节。

## 数据总表

下表为各数据文件的编号—英文文件名对照，并标出每个文件绑定的问题与在解题中的角色。

性质栏口径统一如下：**真实** = 直接观测或公开数据；**半合成** = 基于真实数据校准并叠加噪声；**外推/估算** = 由模型外推或预估，非直接观测；**插值** = 由检查点插值生成；**子集** = 取自其他表的子集，非独立实验；**混合** = 来源口径不完全统一，须分层使用；**参考/说明** = 辅助文件。

### 附件 A（问题一）A\_data\_value/

| 编号 | 英文文件名                                                     | 中文说明                                                     | 性质 | 绑定问题 · 角色   |
|----|-----------------------------------------------------------|----------------------------------------------------------|----|-------------|
| A1 | A_data_value/slimpajama_quality_signal_sample.jsonl.xz    | 质量信号抽样集 (51,230 条, 27 字段; 来自 SlimPajama-Meta-rater 按域抽样) | 真实 | 问题一 · 质量主样本 |
| A2 | A_data_value/slimpajama_quality_extended/arxiv_*.jsonl.xz | arxiv 扩展质量信号                                             | 真实 | 问题一 · 必用    |

| 编号  | 英文文件名                                                        | 中文说明                | 性质 | 绑定问题 · 角色       |
|-----|--------------------------------------------------------------|---------------------|----|-----------------|
| A3  | A_data_value/slimpajama_quality_extended/github_b_*.jsonl.xz | github 扩展质量信号       | 真实 | 问题一 · 必用        |
| A4  | A_data_value/regmix_tables/train_mixture_1m.csv              | 训练配比 (512 组)        | 真实 | 问题一 · 配方 · 训练   |
| A5  | A_data_value/regmix_tables/train_pile_loss_1m.csv            | 训练 Loss             | 真实 | 问题一 · Loss · 训练 |
| A6  | A_data_value/regmix_tables/test_mixture_1m.csv               | 检验配比 1M (256 组)     | 真实 | 问题一 · 配方 · 检验   |
| A7  | A_data_value/regmix_tables/test_pile_loss_1m.csv             | 检验 Loss 1M          | 真实 | 问题一 · Loss · 检验 |
| A8  | A_data_value/regmix_tables/test_mixture_60m.csv              | 检验配比 60M            | 真实 | 问题一 · 配方 · 检验   |
| A9  | A_data_value/regmix_tables/test_pile_loss_60m.csv            | 检验 Loss 60M         | 真实 | 问题一 · Loss · 检验 |
| A10 | A_data_value/regmix_tables/test_mixture_1B.csv               | 检验配比 1B (64 组)      | 真实 | 问题一 · 配方 · 检验   |
| A11 | A_data_value/regmix_tables/test_pile_loss_1B.csv             | 检验 Loss 1B          | 真实 | 问题一 · Loss · 检验 |
| A12 | A_data_value/regmix_tables/est_mixture_10b.csv               | 外推配比 10B (train 子集) | 子集 | 问题一 · 配方 · 外推   |
| A13 | A_data_value/regmix_tables/est_pile_loss_10b.csv             | 外推 Loss 10B         | 外推 | 问题一 · Loss · 外推 |
| A14 | A_data_value/regmix_tables/est_mixture_70b.csv               | 外推配比 70B (train 子集) | 子集 | 问题一 · 配方 · 外推   |
| A15 | A_data_value/regmix_tables/est_pile_loss_70b.csv             | 外推 Loss 70B         | 外推 | 问题一 · Loss · 外推 |
| A16 | A_data_value/domain_mapping_guide.csv                        | 17 域 → 质量域映射表       | 参考 | 问题一 · 域映射       |

| 编号  | 英文文件名                                      | 中文说明    | 性质 | 绑定问题 · 角色               |
|-----|--------------------------------------------|---------|----|-------------------------|
| A17 | A_data_value/regmix_domain_summary.csv     | 域摘要     | 真实 | 问题一 · 辅助（本版未接入求解，供扩展分析） |
| A18 | A_data_value/regmix_domain_sample.jsonl.xz | 域原始文本样例 | 真实 | 可选 · 辅助                 |

说明：A4–A5 为训练表 (train)，A6–A11 为检验表 (test)，A12–A15 为外推表 (est, 即 estimated)。配方表与对应 Loss 表各为一个文件，按 index 列对应。

附件 B（问题二）B\_scaling\_laws/

| 编号  | 英文文件名                                                   | 中文说明                     | 性质  | 绑定问题 · 角色        |
|-----|---------------------------------------------------------|--------------------------|-----|------------------|
| B1  | B_scaling_laws/pythia_training_log_existing.csv         | Pythia 训练日志 (1,176 行)    | 真实  | 问题二 · 主拟合        |
| B2  | B_scaling_laws/cerebras_training_log.csv                | Cerebras 训练日志 (1,029 行)  | 半合成 | 问题二 · 族外验证       |
| B3  | B_scaling_laws/training_trajectories/ (8 个)             | Pythia 插值轨迹 (8×500)      | 插值  | 问题二 · 轨迹验证       |
| B4  | B_scaling_laws/scaling_baseline.csv                     | 跨族收敛点 (57 行, 12 族)       | 真实  | 问题二 · 跨族验证       |
| B5  | B_scaling_laws/published_scaling_data.csv               | 文献标度律数据 (44 行)           | 真实  | 问题二 · 文献验证       |
| B6  | B_scaling_laws/supplementary_NQ_experiment.csv          | NQ 半合成实验 (360 点)         | 半合成 | 问题二 · 质量 Q · 基础  |
| B7  | B_scaling_laws/supplementary_NQ_experiment_expanded.csv | NQ 半合成实验 (450 点)         | 半合成 | 问题二 · 质量 Q · 扩展  |
| B8  | B_scaling_laws/supplementary_NQ_experiment_large.csv    | NQ 半合成实验 (1,704 点, 含外推)  | 半合成 | 问题二 · 质量 Q · 大规模 |
| B9  | B_scaling_laws/supplementary_large_models.csv           | 大模型元数据 (100B–10000B)     | 真实  | 问题二 · 大模型参数      |
| B10 | B_scaling_laws/supplementary_large_baseline.csv         | 大模型预估 Loss (100B–10000B) | 估算  | 问题二 · 大模型外推      |
| B11 | B_scaling_laws/open_model_family_metadata.csv           | 模型族元数据                   | 真实  | 问题二 · 辅助         |

| 编号  | 英文文件名                                           | 中文说明         | 性质 | 绑定问题 · 角色 |
|-----|-------------------------------------------------|--------------|----|-----------|
| B12 | B_scaling_laws/pythia_c<br>checkpoint_index.csv | Pythia 检查点索引 | 真实 | 问题二 · 辅助  |

说明：B1 为主拟合数据；B2/B3 用于模型族外或插值轨迹验证；B4/B5 用于跨族或文献验证；B6–B8 是唯一含质量  $Q$  的数据，用于把  $Q$  纳入标度律；B9/B10 用于百亿参数以上外推。

问题二在问题一输出的质量评分  $Q$  与配比  $p$  基础上构建广义标度律；附件 A 为同一数据集，本问不直接重复读取其原始文件，质量与配比信息通过问题一结果引入。

附件 C（问题三、四）C\_efficiency\_evolution/

| 编号  | 英文文件名                                                               | 中文说明                    | 性质 | 绑定问题 · 角色                  |
|-----|---------------------------------------------------------------------|-------------------------|----|----------------------------|
| C1  | C_efficiency_evolution/<br>leaderboard_cleaned.csv                  | 排行榜（4,576 行，6 维）        | 真实 | 问题四 · 主用                   |
| C2  | C_efficiency_evolution/<br>leaderboard_enhanced.csv                 | 排行榜增强                   | 真实 | 问题四 · 可替代 C1               |
| C3  | C_efficiency_evolution/<br>leaderboard_extended_time_series.csv     | 排行榜时序                   | 混合 | 问题四 · 时序                   |
| C4  | C_efficiency_evolution/<br>epoch_all_ai_models.csv                  | 全模型元数据                  | 真实 | 问题四 · 宏观元数据                |
| C5  | C_efficiency_evolution/<br>loss_benchmark_bridge.csv                | Loss–Benchmark 桥接（43 条） | 混合 | 问题四 · 桥接 · 可对照             |
| C6  | C_efficiency_evolution/<br>loss_benchmark_bridge_expanded.csv       | 桥接扩展（75 条）              | 混合 | 问题四 · 桥接 · 主用              |
| C7  | C_efficiency_evolution/<br>model_architecture_metadata.csv          | 架构元数据（含上下文长度）           | 真实 | 问题三 · 主用；问题四               |
| C8  | C_efficiency_evolution/<br>detailed_results/（1,863 目录 / 1,958 JSON） | 逐任务评测 JSON（约 0.23 GB）   | 真实 | 问题四 · 必用                   |
| C9  | C_efficiency_evolution/<br>data/*.parquet                           | Leaderboard 原始 Parquet  | 真实 | 问题四 · 与 C1 等价（本版未使用，供扩展分析） |
| C10 | C_efficiency_evolution/<br>pythia*_eval_details/                    | 评测说明目录（仅 README）        | 说明 | 参考 · 不可替代 C8               |

说明：问题三除 C7 外，另需使用问题一、二的输出（质量评分、配比、标度律参数）。

数据读取说明

数据可能存在缺失、噪声与冗余，须由参赛队伍自行预处理。大文件已提供 xz 压缩版 (.jsonl.xz)，可用 Python 的 lzma.open() 直接读取，无须解压。

- **流式与分块**：流式即逐行读取，分块即按固定行数批量读取，目的都是避免将大文件一次性载入内存。附件 A 质量信号 JSONL (A1–A3) 宜流式或分块读取；不得以内存为由放弃大文件。
- **大文本字段**：content / text 字段若仅用于统计特征，可不全文入库，仅在线提取统计量。
- **附件 A**：A4 与 A5 通过 index 列对应；配比列为 train\_the\_pile\_\* (17 列)，Loss 列为 metric/the\_pile\*\_val\_loss (13 列)。
- **附件 B**：B1 每行记录某模型在某时刻的 N\_params\_B、D\_tokens\_B 与 val\_loss。
- **附件 C**：C1 含 IFEval、BBH、MATH Lvl 5、GPQA、MUSR、MMLU-PRO 六维得分；C8 下每个子目录对应一个模型的逐任务 JSON。
- **单位换算（全文通用）**：N\_params\_B、D\_tokens\_B 以十亿为单位（如 1.04 表示  $1.04 \times 10^9$ ），代入  $C = 6ND$  时须乘以  $10^9$ ；C\_FLOPs\_1e21 的单位为  $10^{21}$  FLOPs。

强制使用清单

| 优先级  | 路径                                                            | 约计体积              | 绑定问题 | 最低使用方式                                        |
|------|---------------------------------------------------------------|-------------------|------|-----------------------------------------------|
| 必用   | A_data_value/slimpajam<br>a_quality_extended/*.jsonl.xz       | 约 0.04 GB<br>(压缩) | 问题一  | 处理全文记录，估计<br>arxiv/github 域级 $Q$ ，并与<br>抽样集对照 |
| 必用   | A_data_value/slimpajam<br>a_quality_signal_sample.jsonl.xz    | ~0.10 GB (压缩)     | 问题一  | 22 维质量评价与冲突消解<br>主样本                          |
| 必用   | C_efficiency_evolution<br>/detailed_results/                  | ~0.23 GB          | 问题四  | 至少一项逐任务聚合分析                                   |
| 必用   | 附件 A/B/C 全部主 CSV<br>(配方、Pythia、榜单、桥<br>接、架构、Epoch 等)          | 数十 MB             | 各问   | 按赛题要求接入模型                                     |
| 任选其一 | C_efficiency_evolution<br>/data/*.parquet 与 leaderboard/*.csv | ~1 MB             | 问题四  | CSV 与 Parquet 内容等价，<br>不必重复计算                 |

## 跨附件兼容性与表头速查

| 附件 | 核心文件                                                      | 关键字段                                                   | 兼容性与连接键                     |
|----|-----------------------------------------------------------|--------------------------------------------------------|-----------------------------|
| A  | A_data_value/regmix_tables/train_mixture_1m.csv           | index, 17 个域配比                                         | 通过 index 与 Loss 表对应         |
| A  | A_data_value/regmix_tables/train_pile_loss_1m.csv         | index, 13 个域 Loss                                      | 通过 index 与配方表对应             |
| A  | A_data_value/slimpajama_quality_signal_sample.jsonl.xz    | _source_domain, 22 个质量指标                               | 需通过领域映射与 17 域体系建立联系         |
| A  | A_data_value/slimpajama_quality_extended/*.jsonl.xz       | 同质量指标字段                                                | 必用；与抽样集字段一致，覆盖 arxiv/github |
| A  | A_data_value/regmix_domain_sample.jsonl.xz                | text, _source_domain                                   | 可选；辅助跨域映射                   |
| A  | A_data_value/domain_mapping_guide.csv                     | mixture_domain, quality_domain, mapping_type           | 17 个配方域到质量域的参考映射            |
| B  | B_scaling_laws/pythia_training_log_existing.csv           | N_params_B, D_tokens_B, val_loss                       | 真实训练轨迹；标度律拟合核心数据            |
| B  | B_scaling_laws/scaling_baseline.csv                       | family, N_params_B, D_tokens_B, val_loss               | 跨族收敛点；泛化验证                  |
| B  | B_scaling_laws/supplementary_NQ_experiment.csv            | N_params_B, D_tokens_B, Q_score, val_loss              | 半合成 N-D-Q 实验点               |
| C  | C_efficiency_evolution/leaderboard_cleaned.csv            | Model, #Params (B), Submission Date, 6 维得分             | 核心评测表                       |
| C  | C_efficiency_evolution/loss_benchmark_bridge_expanded.csv | Model, Val_Loss, LB_*, Loss_Comparability              | Loss 到 Benchmark 桥接；按可比性分层  |
| C  | C_efficiency_evolution/model_architecture_metadata.csv    | model_name, n_layers, n_heads, max_position_embeddings | 架构和上下文长度分析                  |
| C  | C_efficiency_evolution/detailed_results/                  | 逐任务 JSON                                               | 必用；细粒度评测聚合                  |

附件 A：数据配方实验与质量信号

数据来源

- 配方实验数据：RegMix 项目 (ICML 2024), <https://github.com/sail-sg/regmix>
- 质量信号数据与扩展质量信号 (arxiv、github 两域完整数据文件)：SlimPajama-Meta-rater, <https://huggingface.co/datasets/opendatalab/SlimPajama-Meta-rater>; 其中 A1 抽样集为该数据源各质量信号域的按域抽样记录，非另行生成的独立实验数据

文件结构与说明

| 文件                                                | 格式  | 规模           | 性质 | 说明                            |
|---------------------------------------------------|-----|--------------|----|-------------------------------|
| A_data_value/regmix_tables/train_mixture_1m.csv   | CSV | 512 行 × 18 列 | 真实 | 512 个训练配方，17 个 The Pile 子领域配比 |
| A_data_value/regmix_tables/train_pile_loss_1m.csv | CSV | 512 行 × 14 列 | 真实 | 对应配方的 13 个验证域交叉熵损失            |
| A_data_value/regmix_tables/test_mixture_1m.csv    | CSV | 256 行 × 18 列 | 真实 | 1M 参数规模检验配方                   |
| A_data_value/regmix_tables/test_pile_loss_1m.csv  | CSV | 256 行 × 14 列 | 真实 | 1M 检验配方对应 Loss                |
| A_data_value/regmix_tables/test_mixture_60m.csv   | CSV | 256 行 × 18 列 | 真实 | 60M 参数规模检验配方                  |
| A_data_value/regmix_tables/test_pile_loss_60m.csv | CSV | 256 行 × 14 列 | 真实 | 60M 检验配方对应 Loss               |
| A_data_value/regmix_tables/test_mixture_1B.csv    | CSV | 64 行 × 18 列  | 真实 | 1B 参数规模检验配方                   |
| A_data_value/regmix_tables/test_pile_loss_1B.csv  | CSV | 64 行 × 14 列  | 真实 | 1B 检验配方对应 Loss                |

| 文件                                                         | 格式            | 规模                | 性质 | 说明                                                          |
|------------------------------------------------------------|---------------|-------------------|----|-------------------------------------------------------------|
| A_data_value/regmix_tables/est_pile_loss_10b.csv           | CSV           | 63 行 × 14 列       | 外推 | 10B 尺度预估配方 Loss                                             |
| A_data_value/regmix_tables/est_pile_loss_70b.csv           | CSV           | 63 行 × 14 列       | 外推 | 70B 尺度预估配方 Loss                                             |
| A_data_value/regmix_tables/est_mixture_10b.csv             | CSV           | 63 行 × 18 列       | 子集 | 10B 尺度配比 (train 子集)                                         |
| A_data_value/regmix_tables/est_mixture_70b.csv             | CSV           | 63 行 × 18 列       | 子集 | 70B 尺度配比 (train 子集)                                         |
| A_data_value/regmix_domain_summary.csv                     | CSV           | 17 行 × 5 列        | 真实 | 各领域文本抽样统计信息                                                 |
| A_data_value/domain_mapping_guide.csv                      | CSV           | 17 行 × 4 列        | 参考 | 17 个配方域与质量信号域的映射指南                                          |
| A_data_value/slimpajama_quality_signal_sample.jsonl.xz     | JSONL (xz 压缩) | 51,230 条 × 27 字段  | 真实 | 22 个质量指标, 覆盖 7 个域;<br>SlimPajama-Meta-rater 质量信号按域抽样子集 (必用) |
| A_data_value/slimpajama_quality_extended/arxiv_*.jsonl.xz  | JSONL (xz 压缩) | 17,523 条 × 24 字段  | 真实 | arxiv 域扩展质量信号 (必用, 约 3.5 MB (压缩))                           |
| A_data_value/slimpajama_quality_extended/github_*.jsonl.xz | JSONL (xz 压缩) | 203,752 条 × 24 字段 | 真实 | github 域扩展质量信号 (必用, 约 36 MB (压缩))                           |
| A_data_value/regmix_domain_sample.jsonl.xz                 | JSONL (xz 压缩) | 138,034 条         | 真实 | RegMix 各域原始文本抽样 (可选, 约 0.16 GB (xz 压缩))                     |

性质说明: **真实** = 来自公开论文与数据集的直接观测值。**外推** = est\_pile\_loss\_10b.csv、est\_pile\_loss\_70b.csv 从 1M/60M/1B 三尺度幂律外推, 非直接观测。**子集** = est\_mixture\_10b.csv、est\_mixture\_70b.csv 取自 train 配比子集, 非独立实验。**参考** = domain\_mapping\_guide.csv 为人工整理, 非实验数据。

## 核心字段说明

配方表: `index` 为配方编号; `train_the_pile_*` 共 17 列, 表示 17 个 The Pile 子领域的训练配比 (即领域配比  $p$  的取值), 每行和约为 1 (存在千分位级舍入误差)。

17 个训练领域: `arxiv`, `freelaw`, `nih_exporter`, `pubmed_central`, `wikipedia_en`, `dm_mathematics`, `github`, `philpapers`, `stackexchange`, `enron_emails`, `gutenberg_pg_19`, `pile_cc`, `ubuntu_irc`, `europarl`, `hackernews`, `pubmed_abstracts`, `uspto_backgrounds`。

Loss 表: `index` 对应配方编号; `metric/the_pile_*_val_loss` 共 13 列。17 个训练域中, `nih_exporter`、`enron_emails`、`europarl`、`philpapers` 仅有训练配比列, 无对应交叉熵损失列。参赛队伍可选择保留、合并、正则化处理或仅在训练配比模型中解释其间接影响, 但需说明理由。

质量信号: **A1** 每行一个 JSON 对象, 共 27 个字段, 其中 22 个为质量指标字段 (14 个标量指标 + 8 个多维列表型指标), 其余 5 个为辅助字段 (`id`、`content`、`sub_path`、`_source_domain`、`_source_path`)。**A2/A3** 每行 24 个字段, 为 22 个质量指标、`id` 与 `sub_path`; 已去除 `content`、`_source_domain`、`_source_path`, 来源域由文件名或路径推断。

22 个质量指标: `fineweb_edu`, `fluency_en`, `modernbert_cleanliness`, `modernbert_readability`, `modernbert_reasoning`, `modernbert_professionalism`, `dsir_books`, `dsir_wiki`, `dsir_math`, `qurater`, `ad_en`, `rps_doc_word_count`, `rps_doc_num_sentences`, `rps_doc_unigram_entropy`, `rps_doc_frac_unique_words`, `rps_doc_frac_no_alph_words`, `rps_doc_frac_chars_top_2gram`, `rps_doc_frac_chars_top_3gram`, `rps_lines_uppercase_letter_fraction`, `rps_lines_ending_with_terminal_punctuation`, `rps_lines_numerical_chars_fraction`, `rps_doc_mean_word_length`。

其中 8 个列表型字段需先压缩为标量后再参与建模。扩展集与抽样集的 22 个质量指标字段一致, 宜使用同一套预处理流程。

域映射: 质量信号覆盖 7 个域 (`arxiv`、`book`、`c4`、`commoncrawl`、`github`、`stackexchange`、`wikipedia`), 配方实验涉及上述 17 个域。二者域名并不一一相同。`domain_mapping_guide.csv` 以配方域为行, 给出到质量域的参考对应: `direct` / `near_direct` / `inferred`。其中 `c4` 仅出现在质量信号侧, 配方 17 域中无同名列。

## 附件 B: 模型训练动态轨迹与标度律补充数据

### 数据来源

- Pythia 训练日志: EleutherAI Pythia Scaling Suite, <https://github.com/EleutherAI/pythia>
- Cerebras-GPT 轨迹: 根据 Pythia 标度律和公开 Cerebras-GPT 训练设定校准生成
- 跨族基准点: 从公开模型族文档与论文整理
- 大模型缩放参数: Epoch AI 数据库, [https://epoch.ai/data/all\\_ai\\_models.csv](https://epoch.ai/data/all_ai_models.csv)
- 已发表标度律数据: Kaplan et al. (2020)、Hoffmann et al. (2022) 等文献

文件结构与说明

| 文件                                                      | 格式  | 规模                | 性质  | 说明                              |
|---------------------------------------------------------|-----|-------------------|-----|---------------------------------|
| B_scaling_laws/pythia_training_log_existing.csv         | CSV | 1,176 行 × 15 列    | 真实  | 8 个 Pythia 模型检查点的真实训练轨迹         |
| B_scaling_laws/cerebras_training_log.csv                | CSV | 1,029 行 × 15 列    | 半合成 | 7 个 Cerebras 模型训练轨迹（校准 + 噪声）    |
| B_scaling_laws/scaling_baseline.csv                     | CSV | 57 行 × 5 列        | 真实  | 12 个模型族的跨族收敛基准点                 |
| B_scaling_laws/supplementary_NQ_experiment.csv          | CSV | 360 行             | 半合成 | N-D-Q 实验点                       |
| B_scaling_laws/supplementary_NQ_experiment_expanded.csv | CSV | 450 行             | 半合成 | 扩展版                             |
| B_scaling_laws/supplementary_NQ_experiment_large.csv    | CSV | 1,704 行           | 半合成 | 大规模矩阵，含更大参数外推                   |
| B_scaling_laws/supplementary_large_models.csv           | CSV | 132 行             | 真实  | 100B 以上开源模型缩放参数（Epoch AI 公开报告值） |
| B_scaling_laws/supplementary_large_baseline.csv         | CSV | 128 行             | 估算  | 100B 以上模型预估 Loss                |
| B_scaling_laws/published_scaling_data.csv               | CSV | 44 行              | 真实  | 已发表标度律基准点                       |
| B_scaling_laws/training_trajectories/*.csv              | CSV | 8 × 500 = 4,000 行 | 插值  | 8 个 Pythia 模型插值训练轨迹             |
| B_scaling_laws/pythia_checkpoint_index.csv              | CSV | 1,386 行           | 真实  | Pythia 检查点索引元数据                 |
| B_scaling_laws/open_model_family_metadata.csv           | CSV | 18 行              | 真实  | 模型族仓库元数据                        |

性质说明：**真实** = 直接观测值或公开报告值。**半合成** = cerebras\_training\_log.csv、supplementary\_NQ\_experiment\*.csv 基于真实标度律校准并叠加噪声，非直接实验观测。**估算** = supplementary\_large\_baseline.csv 用已拟合标度律参数估算 Loss，非观测值。**插值** = training\_trajectories/\*.csv 从 Pythia 检查点插值生成。

核心字段说明

pythia\_training\_log\_existing.csv: N\_params\_B 为参数量, D\_tokens\_B 为已训练数据量, C\_FLOPs\_1e21 为累计计算量, val\_loss 为验证集交叉熵损失。四者的单位换算统一见《数据读取说明》。

Pythia 日志中 C\_FLOPs\_1e21 与 6ND 的中位比值约为 1。Cerebras 半合成轨迹已统一 D\_tokens\_B 单位为十亿 tokens, 并与 C\_FLOPs\_1e21 保持 6ND 量级一致。

pythia\_checkpoint\_index.csv 收录多个 Pythia 模型的检查点索引, 而 pythia\_training\_log\_existing.csv 仅包含其中 8 个模型 (约 70M–12B) 的训练轨迹。

标度律数据汇总

| 数据集                               | N 范围       | 来源                |
|-----------------------------------|------------|-------------------|
| Pythia 真实轨迹 (1,176 点)             | 0.07–12B   | EleutherAI Pythia |
| Cerebras 半合成轨迹 (1,029 点)          | 0.11–13B   | Pythia 标度律校准      |
| 跨族收敛基准 (57 点)                     | 0.07–72B   | 12 个模型族公开数据       |
| 已发表基准 (44 点)                      | 约 0.5–280B | 公开论文整理            |
| 大模型缩放参数 (132 点)                   | 100B 以上    | Epoch AI 数据库      |
| N-D-Q 半合成实验 (360 / 450 / 1,704 点) | 含更大参数外推    | 校准 + 插值 + 外推      |

附件 C：模型评测与演进数据

数据来源

- Open LLM Leaderboard v2: <https://huggingface.co/datasets/open-llm-leaderboard-old/results>
- Epoch AI Models Dataset: [https://epoch.ai/data/all\\_ai\\_models.csv](https://epoch.ai/data/all_ai_models.csv)
- 技术报告与模型配置：用于 Loss-Benchmark 桥接和架构元数据整理
- HuggingFace Open LLM Leaderboard 详细评测结果: <https://huggingface.co/datasets/open-llm-leaderboard/results>

文件结构与说明

| 文件                                                             | 格式      | 规模                                | 性质 | 说明                                                                 |
|----------------------------------------------------------------|---------|-----------------------------------|----|--------------------------------------------------------------------|
| C_efficiency_evolution<br>/leaderboard_cleaned.csv             | CSV     | 4,576 行 ×<br>12 列                 | 真实 | 6 维 Benchmark 评测得分                                                 |
| C_efficiency_evolution<br>/leaderboard_enhanced.csv            | CSV     | 4,576 行 ×<br>15 列                 | 真实 | cleaned + Epoch AI 发布日期等                                           |
| C_efficiency_evolution<br>/leaderboard_extended_timeseries.csv | CSV     | 4,599 行 ×<br>11 列                 | 混合 | 约 2019–2025 年时序（含历史模型）                                             |
| C_efficiency_evolution<br>/epoch_all_ai_models.csv             | CSV     | 3,523 行 ×<br>57 列                 | 真实 | Epoch AI 全量模型元数据（不含评测得分）                                           |
| C_efficiency_evolution<br>/loss_benchmark_bridge.csv           | CSV     | 43 行                              | 混合 | 原始 Loss-Benchmark 桥接                                               |
| C_efficiency_evolution<br>/loss_benchmark_bridge_expanded.csv  | CSV     | 75 行                              | 混合 | 扩展桥接（高可比 + 中可比）                                                    |
| C_efficiency_evolution<br>/model_architecture_metadata.csv     | CSV     | 45 行 × 7<br>列                     | 真实 | 主流开源模型架构元数据                                                        |
| C_efficiency_evolution<br>/detailed_results/                   | JSON    | 1,863 个模型子目录 /<br>1,958 个<br>JSON | 真实 | 各模型 6 维 Benchmark 逐任务详细评测结果（必用，约 0.23 GB；4 个 JSON 截断，宜按目录取最新可解析记录） |
| C_efficiency_evolution<br>/pythia*_eval_details/               | 文本      | 7 个目录                             | 说明 | 目前仅含 README（数据集说明），不能替代 detailed_results/ 的逐任务 JSON                |
| C_efficiency_evolution<br>/data/train-00000-of-00001.parquet   | Parquet | 4,576 行 ×<br>36 列                 | 真实 | 原始 Leaderboard Parquet；核心六维与 C1 等价，另含原始附加列，任选其一                    |

性质说明：**真实** = 来自公开 Leaderboard 或公开元数据（含 data/\*.parquet）。**混合** = loss\_benchmark\_bridge\*.csv 的 Loss 来源与验证集不完全统一，须按可比性分层；leaderboard\_extended\_timeseries.csv 不同年份评测标准可能不完全一致。**说明** = pythia\*\_eval\_details

/ 仅含数据集说明文本。

核心字段说明

leaderboard\_cleaned.csv: 关键字段包括 Model、#Params (B)、Submission Date、IFEval / BBH / MATH Lvl 5 / GPQA / MUSR / MMLU-PRO (6 维评测得分)、均分列、Hub License、Type。

leaderboard\_enhanced.csv: 在 cleaned 基础上增加 Epoch AI 相关匹配列。

epoch\_all\_ai\_models.csv: 不包含评测得分，主要提供发布时间、组织、参数量、训练计算量、训练数据量、开源权重等宏观元数据。部分文本字段可能包含换行，建议用标准 CSV 解析后计数。

Loss-Benchmark 桥接: loss\_benchmark\_bridge\_expanded.csv 包含 75 个模型同时具备交叉熵损失与 6 维 Benchmark 得分。其中高可比样本主要来自 Pythia (Loss 可与附件 B 对照)，其余为中可比样本 (Loss 来源于不同技术报告或论文)。Loss\_Comparability 字段标注可比性等级。

模型架构元数据: model\_architecture\_metadata.csv 包含层数、注意力头数、隐藏维度、词表大小、最大上下文长度 (max\_position\_embeddings) 和训练数据量等字段。模型名称与 Leaderboard 的 Model 字段不一定完全一致，匹配时需说明规则。

数据使用说明

- 1. 先满足问题绑定必用集，再展开方法设计；附录须附数据利用清单。
- 2. 半合成与外推数据 (supplementary\_NQ\_experiment\*.csv、cerebras\_training\_log.csv、est\_pile\_loss\*.csv、supplementary\_large\_baseline.csv) 非直接观测，应在论文中标注。
- 3. scaling\_baseline.csv 可用于跨族验证；若用作盲测，应说明其与训练日志的近邻关系。
- 4. 开源筛选可依据 Leaderboard 的 Hub License 或 Epoch AI 的 Open model weights?，须说明口径。
- 5. 三套附件数据源相互独立采集，四问建模逻辑需递进耦合；桥接关系主要通过 Loss、Model、(N, D) 与领域映射建立。
- 6. C8 共 1,863 个模型子目录、1,958 个 JSON；其中 4 个 JSON 截断，1,860 个目录含至少一个可解析 JSON，1,854 个模型六维完整。逐任务聚合时宜按目录取最新可解析记录，跳过损坏文件并说明处理方式。